# Technical Validation 検証プロトコル

GREEN 限定公開版と全 5,200 特徴量カタログ

## Dataset snapshot

| | |
|---|---|
| Element coverage | 118 elements (H-Og) |
| Public interpretable matrix | element_data_interpretable.csv: 822 features (tiers A-C) |
| Public other matrix | element_data_others.csv: 944 features (tiers D-G) |
| Catalogue relationship | 1,766 public + 3,434 licence-excluded optional = 5,200 unique features |

Updated for release v1.0.0 | 2026-07-18

# 1. 目的と適用範囲

本仕様は、公開リリースの構造的完全性、ソース忠実性、再現性、物理・化学的妥当性、解釈分類の信頼性、および権利処理ゲートを、第三者が追試できる証拠付きで検証するためのものとする。

| 項目 | 推奨内容 |
|---|---|
| 対象データ | Public CSVs, public/excluded feature metadata, source registry, licence policy, and Tier-review records |
| 必須ゲート | 構造・再現性・metadata 整合性・数値健全性・GREEN 限定公開・Tier 裁定の追跡可能性 |
| 記述的検証 | 被覆率、欠損パターン、cross-source 差、分布・外れ値、Tier 一致度の可視化 |
| 証拠原則 | 各試験は machine-readable report、ログ、図、サンプル照合表、hash、または裁定表を残す |
| 判定単位 | release tag / DOI version 単位。データまたは Tier 変更ごとに必須試験を再実行する |

# 2. 検証レベルと判定

| 項目 | 推奨内容 |
|---|---|
| PASS | 事前定義した合格基準を満たし、証拠ファイルが保存されている。 |
| PASS WITH NOTE | データの性質として許容される例外があり、理由と影響が明示されている。 |
| FAIL | 合格基準を満たさない。release を停止し修正後に再実行する。 |
| NOT APPLICABLE | 当該 source/block に対象量が存在しない。理由を記録する。 |
| Publication gate | Mandatory かつ Critical/High の試験は、全て PASS または承認済み PASS WITH NOTE であること。 |

# 3. 必須検証群

## 3.1 File and schema integrity

- SHA-256 と manifest の一致。
- 両 CSV が 118 元素、H-Og 順、元素記号一意。
- 公開 CSV の特徴量数が 822 と 944、交差 0、和集合 1,766 である。全カタログは公開 1,766 列とライセンス除外 3,434 列の計 5,200 列である。
- metadata の feature 集合・coverage count が実データと一致。
- 全空列、重複列名、NaN/inf 文字列、不正な非数値セルがない。

### 3.2 Reproducible build

- クリーン環境で release tag から全成果物を再構築。
- 入力 asset の tag/commit/hash を固定。
- 同一環境で 2 回実行し、出力 byte hash を一致させる。
- OS/locale 依存を避けるため、列順、float formatting、改行、encoding を固定。

### 3.3 Source fidelity

- source/block ごとに最低 10 レコード、10 未満なら全件を層化抽出。
- 元素番号域（軽・中・重・人工元素）、欠損有無、条件カテゴリを含める。
- 原値、単位変換、カテゴリ符号化、統計集約、派生式を独立に再計算。
- 直接コピー値は原データの表示精度または定義した数値許容差内で一致。

### 3.4 Physical and chemical consistency

- 正であるべき量の符号、区間の lower<=upper、件数の非負整数性。
- 累積イオン化エネルギーの単調増加、電子配置の電子数整合。
- 天然存在比の和、X 線端・線エネルギー、断面積、半径等の妥当範囲。
- ルール違反は元データ由来か変換不具合かを切り分け、元データ由来なら注記。

### 3.5 Coverage and missingness

- 元素別非欠損数、block 別被覆率、tier 別被覆率を再計算。
- 人工元素、短寿命核種、モデル対象外元素の系統的欠損を可視化。
- 欠損を 0 に置換しない。source-not-covered と not-applicable を可能な範囲で区別。

### 3.6 Duplicate and concordance analysis

- 同一概念候補に canonical_concept_id を付与。
- 完全一致、単位変換一致、参照状態差、定義差を分類。
- 一致を期待する群は事前定義した絶対/相対許容差で比較。
- 異なる定義を持つ列は統合せず、その差を Data Records/Usage Notes で説明。

### 3.7 Interpretability classification

- A-G の判断規則を固定し、全 5,200 列を初回 Tier・行列分割を隠した AI 支援型盲検第二評価へ付した。
- 7 分類の Cohen's kappa は 0.9607、G を除く kappa は 0.9189 であり、事前目標 0.80 を満たした。
- 不一致 120 件を項目単位で裁定し、初回・第二評価・最終 Tier と理由を保存した。公開 CSV 間を移動したのは Miedema モデル量 3 列である。
- モデルの潜在座標、人工演算、経験尺度、pair 集約の境界事例を明示。

### 3.8 Licence release gate

- 各 source にライセンス証拠 URL または保存ファイルを紐付ける。
- GREEN は義務を release 文書へ実装、AMBER は未確定事項を閉じる。
- HOLD は値を公開 release から除外するか、明示許諾を取得する。
- コード、独自 metadata、第三者データ、model-derived vectors のライセンスを分離。

## 4. 数値許容差の原則

| 項目 | 推奨内容 |
|---|---|
| 文字列・カテゴリ・整数 | 完全一致。 |
| 入力値の直接コピー | 原配布精度で完全一致。binary float 比較時は abs<=1e-12 または rel<=1e-12 を既定。 |
| 明示的単位変換 | abs<=1e-10×scale または rel<=1e-10。変換式を metadata に保存。 |
| 統計集約 | 同一欠損除外規則・ddof・重みで再計算し、rel<=1e-10。 |
| 文献丸め値との照合 | 文献の最終有効桁の 0.5 unit 以内。 |
| cross-source 比較 | 品質評価であり原則 pass/fail にしない。equivalent と定義した群のみ閾値判定。 |

## 5. サンプリング仕様

- source-registry 44 件を母集団とし、公開 GREEN 26 件について直接照合を実施し、AMBER/HOLD 18 件はローカル再構築で検証する。
- feature count が 10 未満の source は全 feature を対象にし、各 feature から少なくとも 2 元素を選ぶ。
- 条件依存 block では、電荷/配位/スピン/同位体/エネルギー条件の端点と代表値を含める。
- 欠損率が高い block は、値あり元素と欠損元素を両方含める。
- 抽出 seed を固定し、sample_manifest.csv に source、feature、element、理由を保存する。

## 6. 証拠ファイル

| 項目 | 推奨内容 |
|---|---|
| validation_report.csv | 全試験 ID、状態、実測値、期待値、実行時刻、software commit。 |
| source_fidelity_samples.csv | 原値、変換前後値、許容差、差分、判定、原 URL/ファイル hash。 |
| physical_rule_violations.csv | 規則、対象列・元素、値、原因分類、処置。 |
| coverage_by_element.csv / coverage_by_block.csv | 被覆率再計算の機械可読結果。 |
| duplicate_concordance.csv | canonical concept、equivalence class、変換式、差分統計。 |
| interpretability_adjudication.csv | 全 120 不一致の初回 Tier、盲検第二評価 Tier、裁定 Tier、理由、公開分割への影響。 |
| license_audit.xlsx | source/block 単位の公開可否、義務、証拠、未解決 action。 |
| SHA256SUMS.txt | 入力・出力・文書・図の固定版 hash。 |

## 7. 本文への報告

- 本文 Technical Validation では、検証方法と主要な集計結果を記述し、全試験表は Supplementary/Repository へ置く。
- PASS 33、PASS WITH NOTE 5、DEFERRED 2、FAIL 0 に加え、対象 source 数、照合レコード数、最大差、例外件数、kappa、被覆率範囲を報告する。

- 元データ由来の不整合は修正して隠さず、原値保持と注記のどちらを採用したかを明記する。
- 公開版は GREEN 出典のみとし、AMBER/HOLD 由来 3,434 列を値配布から除外した。Tier 裁定後の公開列数 822/944 を論文・README・manifest で一致させる。

## 8. v1.0.0 実行結果

| 項目 | 推奨内容 |
|---|---|
| 既存構造検証 | 40 tests: PASS 33, PASS WITH NOTE 5, DEFERRED 2, FAIL 0. |
| 現行 hash | element_data_interpretable.csv: 08cac3742cb9…; element_data_others.csv: 7db06c34073c…. |
| 追加必須 | TV-039 tagged GitHub CI and TV-040 DOI-archive hash equivalence. Human expert confirmation is recommended for TV-036 disclosure. |

TV-036 開示：第二評価は AI 支援型の盲検ルーブリック再評価であり、二人目の独立した人間評価者ではない。論文で人間評価者間一致を主張する場合は、専門家による別途確認を行う。